

dbt-llm-testgen

Fiche de projet — génération de tests et de documentation dbt par un LLM

Objectif

Construire un petit entrepôt de données (prêts Kiva, inclusion financière Findex) avec dbt, puis comparer les tests et la documentation écrits à la main à ceux proposés par un LLM à partir du seul profiling des colonnes. Mesurer la précision et le rappel de cette génération automatique.

Informations générales

Statut	En cours — phase de mise en place
Portée	Projet personnel d'apprentissage, échelle réduite (MVP)
Durée prévue	8 week-ends, environ 2 mois
Dépôt	Public, GitHub
Licence des données	Données ouvertes (Kiva, Global Findex — Banque mondiale)

Sources de données

- **Kiva** — données de prêts (montant, pays, secteur, statut)
- **Global Findex** (Banque mondiale) — indicateurs d'inclusion financière, format CSV

Architecture

API Kiva + CSV Findex → scripts d'extraction Python → DuckDB (schema raw)
→ dbt staging → dbt intermediate → dbt marts (fact_loans, dim_country, dim_sector)
→ tests écrits à la main *et* tests générés par LLM, comparés
→ Airflow orchestre `dbt run` et `dbt test`

Stack technique

Langage	Python
Entrepôt	DuckDB (local, fichier unique)
Transformation	dbt-core, dbt-duckdb, dbt-utils
Orchestration	Apache Airflow (Docker)
LLM	API Mistral ou Groq (clé gratuite)

Protocole d'évaluation

Pour chaque modèle dbt : profiling des colonnes (taux de nulls, valeurs distinctes, min/max), envoi au LLM avec une demande de sortie YAML stricte, puis comparaison manuelle avec les tests écrits à la main.

- **Précision** = tests LLM corrects / total des tests proposés par le LLM
- **Rappel** = tests LLM corrects / total des tests qu'un humain jugerait nécessaires

Sécurité et bonnes pratiques

- Aucune clé d'API ou identifiant dans le dépôt — tout passe par un fichier `.env` local, ignoré par git
- Base de données locale (`*.duckdb`) et logs exclus du dépôt
- Branche `main` protégée — aucun push direct, fusion uniquement par pull request relue et validée
- Travail quotidien sur des branches dédiées

Limites connues

- Échelle volontairement réduite (15 à 20 modèles dbt, pas 300+)
- Comparaison humain/LLM faite manuellement, pas d'outil de suivi automatisé pour l'instant
- Une seule source géospatiale écartée pour l'instant (FEWS NET)